



ENVI - Uheldsmodel for veje

Mads Werngreen - mawn@vd.dk

20. marts 2026

Indhold

1	Indledning	1
2	Data	2
2.1	Grøn Mobilitetsmodel (GMM)	2
2.2	Politiregistrerede Uheld	2
2.3	Sammenfletning af Datakilder	4
3	Model	4
3.1	Notation	5
3.2	Modeloversigt	6
3.3	MAP-estimation	7
3.3.1	Likelihood	7
3.3.2	Prior	8
3.3.3	Posterior	8
3.4	Opdatering af hyperparametre σ	8
3.5	Model Input	10
4	Validering af Model	13
4.1	k -fold cross-validation	13
4.2	Randomized Quantile Residuals (RQR)	14
4.3	T-test	15
4.4	χ^2 -test	15
4.5	Kolmogorov–Smirnov-test	16
5	Resultater	16
6	Diskussion	21
7	Bilag	24
7.1	Github-Repository	24
7.2	Forventet ulykkestal ved vejopdeling	24
7.3	Udledninger af Log-likelihood og Hessematricer fro hver model	25
7.3.1	Totalt antal uheld	25
7.3.2	Antal personskadeuheld	27
7.3.3	Antal tilskadekomne	28

1 Indledning

ENVI-modellen estimerer de samfundsøkonomiske gevinster ved et infrastrukturprojekt, herunder de samlede omkostninger ved trafikuheld. I ENVI opdeles uheld i to hovedtyper: personskadeuheld og materielskadeuheld. Hver type har sin egen samfundsøkonomiske enhedsomkostning, baseret på de officielle prissætninger for uheldstyperne. Et personskadeuheld er defineret som et uheld, hvor mindst én person kommer til skade, mens et materielskadeuheld er et uheld uden tilskadekomne. For personskadeuheld klassificeres hver tilskadekomne som let, svært eller fatalt tilskadekomne. Hver af disse skadestyper har en tilhørende samfundsøkonomisk omkostning. Den samlede omkostning for et uheld beregnes derfor som summen af antallet af tilskadekomne i hver kategori multipliceret med den respektive enhedsomkostning, plus en basisomkostning for selve uheldstypen (personskade eller materielskade). For at tage højde for effekterne af et infrastrukturprojekt estimeres den samfundsøkonomiske gevinst, og hertil ønskes det at kunne bidrage med uheldsomkostninger baseret på et modeloutput fra Grøn Mobilitets Model (GMM).

Formålet med denne artikel er at udvikle og validere en model, der kan estimere antallet af uheld på veje fordelt på to typer samt antallet af tilskadekomne i tre skadeskategorier. Modellen kan herefter implementeres i ENVI for at give et mere præcist estimat af de økonomiske konsekvenser af trafikuheld.

Til denne type estimeringsopgave findes flere mulige metoder. Man kan eksempelvis anvende neurale netværk til at opfange ikke-lineære sammenhænge [5]. Brugen af neurale netværk anses dog ofte for en såkaldt black box-løsning. Som et mere simpelt og gennemsigtigt alternativ kan man anvende Poisson regression [14]. Denne model har dog ofte problemer med over-dispersion, idet variansen i praksis typisk overstiger middelværdien [7].

En mere fleksibel tilgang er at anvende negativ binomial regression, som eksPLICIT tager højde for over-dispersion i tælledata [7]. Da uheldsdata samtidig ofte indeholder et stort antal nulobservationer (vejsegmenter uden uheld), kan en Zero-Inflated Negative Binomial (ZINB) model være særligt velegnet, idet den både håndterer over-dispersion og et stort antal nul-observationer [1].

De størrelser, der skal estimeres for hvert vejsegment, er indbyrdes korrelerede. Eksempelvis afhænger antallet af skader af, om der overhovedet er sket et personskadeuheld—hvis der ikke er sket nogen personskader, må antallet af skader nødvendigvis være nul. Af den grund kan en hierarkisk modelstruktur være fordelagtig.

I den valgte model opbygges strukturen hierarkisk. Først estimeres det samlede antal uheld under antagelsen af, at antallet følger en negativ binomialfordeling. Dette resultat anvendes derefter som input til modellen for antallet af personskadeuheld, hvor en binomialfordeling benyttes. Denne estimering anvendes

des ligeledes som input til tre separate modeller, der hver estimerer antallet af henholdsvis lette, alvorlige og fatale personskader. Til alle tre modeller benyttes en negativ binomial-fordeling.

2 Data

Dette afsnit beskriver de data, som anvendes til estimering af parametre i ulykkesmodellen. Data kan deles op i to hovedkilder: GMM-databasen og et datasæt bestående af alle politiregistrerede uheld for perioden 01.01.2014 - 31.12.2023.

2.1 Grøn Mobilitetsmodel (GMM)

Der benyttes data fra Grøn Mobilitetsmodel - version 4.0. Herunder er statistiske informationer om vejnettet og data bestående af modellerede hastigheder og trafikmængder.

Vejnet og vejgeometri

GMM-vejnettet indeholder geometriske oplysninger og hastighedsbegrænsninger for hvert vejsegment. Herunder indgår længde, antal vognbaner, skiltet hastighed, byzoneklassifikation, tilknyttet GMM-zone for vejsegmentet og rumlige oplysninger, der angiver både lokation og form på vejen.

Trafikdata

Til estimeringen af modellen anvendes estimeret trafikdata fra en GMM - version 4.0 basis 2023 beregning (dataudtræk fra 20-08-2025). Denne data består af gennemsnitshastigheder og trafikmængder fordelt på forskellige kategorier som kan henføres til køretøjstyper via kategorinøgle fra Tabel 1.

GMM-data bearbejdes til et datasæt, hvor output er antal køretøjer og gennemsnitshastighed per dag opdelt i to køretøjskategorier: **Car** og **Truck**. Kategorien **Car** dækker både personbiler og varevogne, mens **Truck** udelukkende omfatter lastbiler. Denne opdeling konstrueres ved at aggregere over alle **TimeInteID** og **CategoryID**, hvor **CategoryID** er knyttet til de **TrafTypeID**, der tilhører den ønskede køretøjskategori. Alle **Vejkarakteristika** er konstante på tværs af **TimeInteID** og kobles derfor til trafikdata udelukkende via **LinkID**. Hermed indgår en modelantagelse om, at vejens form og hastighedsgrænse ikke varierer over tid. En konsekvens heraf er, at modellen ikke umiddelbart kan håndtere vejsegmenter med adaptive hastighedsgrænser.

2.2 Politiregistrerede Uheld

De politiregistrerede uheld tilknyttes vejnettet ved at identificere det nærmeste vejsegment til hver enkelt uheld, hvorefter uheldet tildeles det korresponderende **LinkID**. Kun uheld inden for en afstand på x meter fra et gyldigt vejsegment medtages. Afstanden x fastsættes således, at uheld fra nærliggende,

Trafikdata		
Variable	Beskrivelse	Datatype
LinkID	Unikt ID til hvert vejsegment	int
TimeInteID	Tidsinterval ID	int
CategoryID	Kategori ID	int
TotalTraf	Total trafikmængde	float
AvgSpeed	Gennemsnitlig hastighed	float
Kategorinøgle		
Variable	Beskrivelse	Datatype
CategoryID	Kategori ID	int
TrafTypeID	ID for køretøjsgruppen	int
Name	Beskrivelse af kategori	string
Vejkarakteristika		
Variable	Beskrivelse	Datatype
LinkID	Unikt ID til hvert vejsegment	int
LinkTypeID	ID som beskriver link type	int
FreeSpeed	Skiltet hastighed	int
LanesFor	Antal spor i kørselsretning med tegneretningen	int
LanesBack	Antal spor i kørselsretning mod tegneretningen	int
LaneHCFor	Kapacitet pr. spor (med tegneretningen)	int
LaneHCBack	Kapacitet pr. spor (mod tegneretningen)	int
Length	Længde af vejsegment	float
URBAN	Indikator for by- og miljøzone	int
WKT	Vejgeometri	Linestring

Tabel 1: Brugt data fra GMM-databasen opdelt på vejkarakteristika, kategorinøgle og trafikdata.

Rå kolonner	Beskrivelse	Datatype
ANTAL_DRAE	Antal dræbte i uheldet	int
ANTAL_TILS	Antal tilskadekomne i uheldet	int
AAR	År for uheldet	int
X_KOORDINAT	x-koordinat i crs: ESPG 28532	float
Y_KOORDINAT	y-koordinat i crs: ESPG 28532	float
Afledte kolonner	Beskrivelse	Datatype
LinkID	ID for nærmeste vejsegment	int
Personskade	$ANTAL_DRAE + ANTAL_TILS > 0$	binary
Materielskade	$ANTAL_DRAE + ANTAL_TILS == 0$	binary

Tabel 2: Kolonner fra uheldsshapefilen brugt i forbehandlingen, opdelt i rå og afledte felter

men irrelevante veje ekskluderes, samtidig med at mindre fejl i positionsangivelsen samt unøjagtigheder i digitaliseringen af vejsegmenterne accepteres. x er valgt til 15 m. Til at identificere det nærmeste vejsegment anvendes funktionen `sjoin.nearest`, som er implementeret i `geopandas` [6]. Uheldene aggregeres til et antal personskadeuheld og et antal materielskadeuheld for hvert `LinkID` og kobles dernæst sammen med de øvrige GMM- og trafikdata.

2.3 Sammenfletning af Datakilder

Det resulterende datasæt indeholder én række per `LinkID` med trafikdata, vej-karakteristika og summerede uheldsdata. Den indledende model baseres udelukkende på trafikdata og uheldsdata fra 2023. Dette skyldes, at trafikdata ikke er tilgængelige for øvrige år, og at uheldsdata før 2023 i højere grad kan være påvirket af ændrede mobilitetsmønstre som følge af COVID-19-pandemien. En central antagelse i analysen er derfor, at vejrforholdene i 2023 ikke har haft en væsentlig indflydelse på det samlede antal uheld. Hvorvidt denne antagelse er rimelig, er imidlertid vanskeligt at vurdere. Eksempelvis var nedbørsmængden i 2023 cirka 29% over normalen [4], hvilket potentielt kan have påvirket ulykesniveauet. Effekten af øget nedbør er dog ikke entydig, da den både kan føre til flere uheld (fx pga. glatte vejforhold) og færre uheld (fx pga. lavere hastigheder og ændret adfærd). Da vejrforhold ikke indgår som forklarende variabel i GMM, er de ikke inkluderet i modellen eller den videre analyse. Endvidere antages det, at den realiserede trafik i 2023 i tilstrækkelig grad svarer til den trafik, der estimeres af GMM.

3 Model

Dette afsnit redegør for den anvendte model, herunder den hierarkiske struktur og de forklarende variable. Modellen består af tre niveauer, der hver beskriver et centralt aspekt af uheldsprocessen.

Variabelnavn	Oprindelse	Datatype
LinkID	GMM / Uheld	int
LinkTypeID	GMM	int
AvgSpeed_Car	GMM	float
AvgSpeed_Truck	GMM	float
TotalTraf_Car	GMM	float
TotalTraf_Truck	GMM	float
Length	GMM	float
FreeSpeed	GMM	float
Lanes	GMM	int
URBAN	GMM	binary
GMM_ZoneID	GMM	int
Antal_Personskade	Uheldsdata	int
Antal_Materielskade	Uheldsdata	int

Tabel 3: Endelige kolonner i `uheld`-dataframe til brug i modelinput, inkl. oprindelse og datatype

3.1 Notation

- Skalarer: $x, \theta_j, \sigma_j, \alpha$
- Vektorer: $\mathbf{x}, \boldsymbol{\theta}, \boldsymbol{\beta}, \boldsymbol{\gamma}, \boldsymbol{\delta}^{(j)}$
- Matricer: $\mathbf{X}, \mathbf{Z}, \mathbf{W}, \mathbf{H}, \mathbf{D}$

Indeksering

lad $\mathbf{A}$ være en matrix, så er række i givet ved $\mathbf{a}_i$ og et element givet ved a_{ij}

$$\mathbf{A} = \begin{pmatrix} - & \mathbf{a}_1 & - \\ - & \mathbf{a}_2 & - \\ & \vdots & \\ - & \mathbf{a}_n & - \end{pmatrix} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1m} \\ a_{21} & a_{22} & \dots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nm} \end{pmatrix}$$

lad $\mathbf{a}$ være en vektor, så er element i givet ved a_i

$$\mathbf{a} = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix}$$

Sandsynligheder og fordelinger

$\mathbb{P}(\cdot)$ betegner sandsynlighed

Betingede fordelinger

Notation af typen

$$\mathbb{P}(Y | X)$$

angiver den betingede sandsynlighed af Y givet X .

Forventning og varians

Forventningsværdien og variansen af en stokastisk variabel X betegnes henholdsvis $\mathbb{E}(X)$ og $\text{Var}(X)$.

Matrix vektor operatører

$\nabla_x^2 f = \frac{\partial^2 f}{\partial \mathbf{x} \partial \mathbf{x}^\top}$ er Hesse matricen for $f : \mathbb{R}^n \mapsto \mathbb{R}$

for $\mathbf{x} \in \mathbb{R}^n$ så er $\text{diag}(\mathbf{x})$ diagonalmatricen, hvis diagonalelementer er givet ved komponenterne i $\mathbf{x}$. For $\mathbf{X} \in \mathbb{R}^{n \times n}$ så er $\text{diag}(\mathbf{X})$ den vektor, hvis elementer er givet ved diagonalen i $\mathbf{X}$

3.2 Modeloversigt

For hvert vejlink i modelleres følgende størrelser:

- Det totale antal uheld: N_i
- Antallet af personskadeuheld: Y_i
- Antal let tilskadekomne: $q_i^{(1)}$
- Antal svært tilskadekomne: $q_i^{(2)}$
- Antal dødsfald: $q_i^{(3)}$

Disse størrelser antages at følge den hierarkiske struktur

$$\mathbb{P}(N_i, Y_i, q_i^{(1)}, q_i^{(2)}, q_i^{(3)}) = \mathbb{P}(N_i) \mathbb{P}(Y_i | N_i) \prod_{j=1}^3 \mathbb{P}(q_i^{(j)} | Y_i), \quad (1)$$

Dette afspejler følgende antagelser:

- N_i beskriver det totale antal politiregistrerede uheld.
- Y_i beskriver antallet af uheld, der medfører personskade. Da Y_i er korreleret med det totale antal uheld, modelleres Y_i betinget på N_i , dvs. $Y_i | N_i$.
- $q_i^{(j)}$ beskriver antallet af tilskadekomne i skadeskategori $j \in \{\text{let, svær, dødelig}\}$. Disse størrelser er korrelerede gennem Y_i , men antages betinget uafhængige givet en realisering af Y_i .

Hver af delmodellerne har følgende distributioner og parametriseringer:

Totalt antal uheld (NB2).

$$N_i \sim \text{NB2}(\mu_i, \alpha_y), \quad \mu_i = \lambda_i \exp(X_i^\top \beta), \quad (2)$$

hvor $\mathbb{E}(N_i) = \mu_i$, og hvor λ_i betegner trafikarbejdet, defineret som

$$\lambda_i = \text{længde} \times \text{antal køretøjer} \quad \text{for vejsegment } i.$$

Antal personskadeuheld (Binomial).

$$Y_i \sim \text{Binomial}(N_i, p_i), \quad p_i = \text{logit}^{-1}(Z_i^\top \gamma). \quad (3)$$

hvor $\mathbb{E}(Y_i) = \mathbb{E}(\mathbb{E}(Y_i|N_i)) = p_i \mu_i$

Skadesgrader (tre NB2-modeller). For hver skadegrad $j = 1, 2, 3$:

$$q_i^{(j)} \sim \text{NB2}(\mu_i^{(j)}, \alpha_j), \quad \mu_i^{(j)} = Y_i \exp(W_i^\top \delta^{(j)}). \quad (4)$$

hvor $\mathbb{E}(q_i^{(j)}) = \mathbb{E}(\mathbb{E}(q_i^{(j)}|Y_i)) = \mu_i^{(j)} p_i \mu_i$

3.3 MAP-estimation

Modellens parametre samles i en samlet parametervektor

$$\boldsymbol{\theta} = (\boldsymbol{\beta}, \alpha_N, \boldsymbol{\gamma}, \boldsymbol{\delta}^{(1)}, \alpha_1, \boldsymbol{\delta}^{(2)}, \alpha_2, \boldsymbol{\delta}^{(3)}, \alpha_3). \quad (5)$$

Disse ønskes estimeret ved et *Maximum a Posteriori* (MAP) estimat. givet datasættet:

$$\mathcal{D} = \{N_i, Y_i, \delta_i^{(1)}, \delta_i^{(2)}, \delta_i^{(3)}\}_{i=1}^n. \quad (6)$$

Under antagelse om uafhængige Gaussiske priors for alle parametre (undtagen intercepts og dispersionsparametre), gælder Bayes' regel

$$\underbrace{\mathbb{P}(\boldsymbol{\theta} | \mathcal{D}, \boldsymbol{\sigma})}_{\text{posterior}} = \frac{\overbrace{\mathbb{P}(\mathcal{D} | \boldsymbol{\theta})}^{\text{likelihood}} \overbrace{\mathbb{P}(\boldsymbol{\theta} | \boldsymbol{\sigma})}^{\text{prior}}}{\underbrace{\mathbb{P}(\mathcal{D} | \boldsymbol{\sigma})}_{\text{evidence}}}. \quad (7)$$

Her betegner $\boldsymbol{\sigma}$ en hyperparameter, som indgår i priorfordelingen og dermed styrer modellens regularisering.

MAP-estimatet defineres som

$$\hat{\boldsymbol{\theta}}_{\text{MAP}} = \arg \max_{\boldsymbol{\theta}} \mathbb{P}(\boldsymbol{\theta} | \mathcal{D}, \boldsymbol{\sigma}). \quad (8)$$

I praksis minimeres den negative log-posterior. Da evidensen $\mathbb{P}(\mathcal{D} | \boldsymbol{\sigma})$ er konstant med hensyn til $\boldsymbol{\theta}$, kan den udelades:

$$\hat{\boldsymbol{\theta}}_{\text{MAP}} = \arg \min_{\boldsymbol{\theta}} \left\{ -\log \mathbb{P}(\mathcal{D} | \boldsymbol{\theta}) - \log \mathbb{P}(\boldsymbol{\theta} | \boldsymbol{\sigma}) \right\}. \quad (9)$$

Denne optimering udføres numerisk ved hjælp af L-BFGS-B algoritmen[3].

3.3.1 Likelihood

Den hierarkiske model har likelihood:

$$\mathbb{P}(\mathcal{D} | \boldsymbol{\theta}) = \prod_{i=1}^n \mathbb{P}(N_i | \boldsymbol{\beta}, \alpha_y) \mathbb{P}(Y_i | N_i, \boldsymbol{\gamma}) \prod_{j=1}^3 \mathbb{P}(\delta_i^{(j)} | Y_i, \boldsymbol{\delta}^{(j)}, \alpha_j). \quad (10)$$

3.3.2 Prior

De penaliserede parametre antager uafhængige Gaussiske priors:

$$\beta_{1:} \sim \mathcal{N}(0, \sigma_\beta^2 I), \quad \gamma_{1:} \sim \mathcal{N}(0, \sigma_\gamma^2 I), \quad \delta_{1:}^{(j)} \sim \mathcal{N}(0, \sigma_j^2 I), \quad j = 1, 2, 3. \quad (11)$$

Log-prioren bliver dermed

$$\log \mathbb{P}(\theta) = -\frac{1}{2} \left[\frac{\|\beta_{1:}\|^2}{\sigma_\beta^2} + \frac{\|\gamma_{1:}\|^2}{\sigma_\gamma^2} + \sum_{j=1}^3 \frac{\|\delta_{1:}^{(j)}\|^2}{\sigma_j^2} \right] + \text{const.} \quad (12)$$

3.3.3 Posterior

Posteriorfordelingen følger af Bayes' regel (7) da evidensen er konstant med hensyn til θ undlades dette led, hvilket giver:

$$\mathbb{P}(\theta \mid \mathcal{D}) \propto \mathbb{P}(\mathcal{D} \mid \theta) \mathbb{P}(\theta). \quad (13)$$

Den fulde posterior kan dermed skrives som

$$\mathbb{P}(\theta \mid \mathcal{D}) \propto \prod_{i=1}^n \left[\mathbb{P}(N_i \mid \beta, \alpha_y) \mathbb{P}(Y_i \mid N_i, \gamma) \prod_{j=1}^3 \mathbb{P}(\delta_i^{(j)} \mid Y_i, \delta^{(j)}, \alpha_j) \right] \mathbb{P}(\theta) \quad (14)$$

hvilket giver følgende negative log posterior

$$-\log \mathbb{P}(\theta \mid \mathcal{D}, \sigma) \propto \sum_{i=1}^n \left[-\ell(\beta, \alpha_y) - \ell(\gamma) - \sum_{j=1}^3 \ell(\delta^{(j)}, \alpha^{(j)}) \right] - \log \mathbb{P}(\theta) \quad (15)$$

i log posterior indgår log likelihood ℓ for hver del-model som udledes i bilag og er defineret ved (37), (49), (61). Desuden indgår log prior som er defineret i (12)

3.4 Opdatering af hyperparametre σ

De Gaussiske priors antager, at hver parameter (undtagen intercepts og dispersionsparametre) opfylder

$$\theta_j \sim \mathcal{N}(0, \sigma_j^2), \quad j = 1, \dots, P. \quad (16)$$

Hyperparametrene σ_j bestemmer således styrken af regulariseringen (hvor meget modellens parametre tillades at afvige fra nul). I stedet for at fastsætte disse manuelt estimeres de iterativt ved momentmatching.

Momentmatching: Opdatering af σ

Andet moment for prior ($\mathbb{E}_{\text{prior}}(\theta_j^2) = \sigma_j^2$) sættes lig med andet moment for posterior ($\mathbb{E}(\theta_j^2) = \mathbb{E}(\theta_j)^2 + \text{Var}(\theta_j)$) hvilket giver opdateringsreglen:

$$\sigma_j^2 \leftarrow \hat{\theta}_j^2 + \text{Var}(\theta_j \mid \mathcal{D}, \sigma). \quad (17)$$

Variansen approksimeres lokalt omkring MAP-estimatet $\hat{\boldsymbol{\theta}}_{\text{MAP}}$ via en Laplace-approksimation, hvilket giver

$$\text{Var}(\boldsymbol{\theta} \mid \mathcal{D}, \boldsymbol{\sigma}) \approx \mathbf{H}_{\text{post}}^{-1}. \quad (18)$$

hvor præcisionsmatrixen $\mathbf{H}_{\text{post}}$ er givet ved den negative Hessian af log-posterior evalueret i $\boldsymbol{\theta} = \hat{\boldsymbol{\theta}}_{\text{MAP}}$:

$$\mathbf{H}_{\text{post}} = -\nabla_{\boldsymbol{\theta}}^2 \log \mathbb{P}(\boldsymbol{\theta} \mid \mathcal{D}, \boldsymbol{\sigma}) \Big|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}_{\text{MAP}}} = -\nabla_{\boldsymbol{\theta}}^2 \log \mathbb{P}(\mathcal{D} \mid \boldsymbol{\theta}) \Big|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}_{\text{MAP}}} + \text{diag}(\boldsymbol{\sigma}^{-2}). \quad (19)$$

Præcisionsmatrixen $\mathbf{H}_{\text{post}}$ kan fortolkes som et lokalt mål for, hvor stærkt data og prior tilsammen fastholder parametrene omkring MAP-estimatet; dens inverse giver et approksimeret mål for parameterusikkerheden.

Denne opdatering kan fortolkes som:

- hvis $\hat{\theta}_j$ er stor (parameteren er vigtig), vokser σ_j
- hvis usikkerheden er stor (den approksimerede varians høj), vokser σ_j
- hvis parameteren er tæt på nul og sikker, falder σ_j , hvilket styrker regulariseringen

Dette giver en automatisk balance mellem fleksibilitet og regularisering [2].

Praktisk implementering

Log-likelihooden faktoriserer i separate bidrag for de enkelte delmodeller, hvor hver parametergruppe kun indgår i én komponent af likelihooden. Den Hessiske matrix for log-likelihooden bliver derfor blokdiagonal med hensyn til parametergrupperne ($\boldsymbol{\beta}$, $\boldsymbol{\gamma}$ og $\boldsymbol{\delta}^{(j)}$).

I implementeringen udnyttes denne struktur ved at approksimere præcisionsmatrixen $\mathbf{H}_{\text{post}}$ blokvist, således at hver blok kan behandles separat ved beregning af den approksimerede posteriorvarians. Derved kan inversionen udføres på mindre matricer for hver parametergruppe.

For en given parameterblok x med parametervektor $\mathbf{x}$ er den tilhørende præcisionsmatrix givet ved

$$\mathbf{H}_{\text{post}}^{(x)} = -\mathbf{H}_{\ell}^{(x)} + \text{diag}\left((\boldsymbol{\sigma}^{(x)})^{-2}\right), \quad (20)$$

hvor $\mathbf{H}_{\ell} = \nabla_{\boldsymbol{\theta}}^2 \log \mathbb{P}(\mathcal{D} \mid \boldsymbol{\theta})$ er likelihood-Hessianen evalueret i $\boldsymbol{\theta} = \hat{\boldsymbol{\theta}}_{\text{MAP}}$, $\mathbf{H}_{\ell}^{(x)}$ betegner den del, der tilhører blok x (intercept fjernet), og $\boldsymbol{\sigma}^{(x)}$ er de tilhørende hyperparametre. Den approksimerede posteriorvarians bestemmes som diagonalen af den inverse præcisionsmatrix hvilket giver Opdateringen af hyperparametrene i blok x ved momentmatching-reglen (17):

$$\boldsymbol{\sigma}_{\text{new}}^{(x)} = \sqrt{\hat{\mathbf{x}}^2 + \text{diag}\left((\mathbf{H}_{\text{post}}^{(x)})^{-1}\right)}. \quad (21)$$

hvor $\hat{\mathbf{x}}^2$ er variable i $\boldsymbol{\theta}_{\text{MAP}}$ som relatere sig til model x . Præcisionsmatrixen $\mathbf{H}_{\text{post}}^{(x)}$ udledes i bilag og er givet ved (43), (54) og (68) afhængigt x beskriver henholdsvis Total antal uheld (β), Antal personskade uheld (γ), eller skadsegrad ($\delta^{(j)}$)

For numerisk stabilitet anvendes en dæmpet opdatering:

$$\boldsymbol{\sigma}_{t+1}^{(x)} = (1 - \lambda) \boldsymbol{\sigma}_t^{(x)} + \lambda \boldsymbol{\sigma}_{\text{new}}^{(x)}, \quad \lambda \in (0, 1), \quad (22)$$

hvor $\lambda = 0.3$ anvendes i denne analyse. Denne dæmpning reducerer numeriske udsving og sikrer konvergens i den iterative momentmatching-procedure.

3.5 Model Input

Data-matricerne

$$\begin{aligned} \mathbf{X} &\equiv (x_{ip}) \in \mathbb{R}^{N \times n_x} \\ \mathbf{Z} &\equiv (z_{ip}) \in \mathbb{R}^{N \times n_z} \\ \mathbf{W} &\equiv (w_{ip}) \in \mathbb{R}^{N \times n_w} \end{aligned}$$

Disse matricer kan indeholde attributter som er beskrevet i de to følgende delafsnit

Numeriske Input

Den numeriske blok består af værdierne:

$$\begin{aligned} \text{Intercept} &= 1 \\ \text{Frac_Truck} &= \frac{\text{TotalTraf_Truck}}{\text{TotalTraf_Truck} + \text{TotalTraf_Car}} \\ \text{SpeedDiff_Car} &= \text{FreeSpeed} - \text{AvgSpeed_Car} \\ \text{SpeedDiff_Truck} &= \text{FreeSpeed} - \text{AvgSpeed_Truck} \\ \text{Lanes} &\quad (\text{ikke ændret}) \end{aligned}$$

Kategoriske Input

Den kategoriske del af inputvariablene er baseret på tre informationskilder:

1. URBAN
2. LinkTypeID
3. GMM_ZoneID

Linkgrupper

For at reducere dimensionaliteten og samtidigt bevare den funktionelle forskel mellem linktyper opdeles **LinkTypeID** i fire kategorier, benævnt **Link_group_0** til **Link_group_3**. Disse grupper anvendes som one-hot encodede variable og beskrives som følger:

Link_group_0 – Motorveje

- Indeholder: **LinkTypeID** = 1
- Typisk høj hastighed (op til 130 km/t)
- Ingen interaktion med trafik kryds

Link_group_1 – Store veje og hovedveje

- Indeholder: **LinkTypeID** = 3, 4, 5, 7, 9
 - Motortrafikveje (3)
 - Nationale hovedveje (4)
 - Store trafikveje (5)
 - Regionale veje (7)
 - Trafikveje (9)

Link_group_2 – Trafiksanerede veje


- Indeholder: **LinkTypeID** = 6, 8, 10
 - Trafiksaneret stor trafikvej (6)
 - Trafiksaneret regional vej (8)
 - Trafiksaneret trafikvej (10)
- Kendetegnet ved lavere hastighedsniveau end gruppe og beliggende i bymiljøer

Link_group_3 – Ramper

- Indeholder: **LinkTypeID** = 2, 11
 - Motorvejsramper (2)
 - Øvrige ramper (11)
- Kendetegnet ved acceleration/deceleration
- Hyppig fletning og afvigelse

Geografiske Kategorier (GMM-Zoner)

For den geografiske variabel `GMM_ZoneID` anvendes one-hot encoding. Da antallet af zoner er stort, aggregeres zonerne til regioner. Formålet er at reducere dimensionaliteten. Zonerne reduceres således, at den geografiske inddeling svarer til de danske regioner; se Figur 1. Antallet af niveau-3 GMM-zoner med motorvejsstrækninger er 258, hvorimod antallet af regioner er 5.



Figur 1: GMM-niveau-3-zoner opdeles i regioner, hvilket reducerer antallet af nødvendige one-hot-kolonner betydeligt.

Denne aggregering løser desuden et estimeringsproblem: Ikke alle zoner indeholder motorveje, hvorfor effekterne ellers kun ville kunne estimeres for et subset af zonerne. I modsætning hertil indeholder alle regioner motorvejsstrækninger, hvilket muliggør estimation af en generel model.

Som resultat af aggregeringen og one-hot encoding af `GMM_ZoneID` fås fem indikatorvariabler:

1. Region Hovedstaden
2. Region Sjælland
3. Region Syddanmark
4. Region Midtjylland
5. Region Nordjylland

URBAN

Variablen `URBAN` angiver om vejsegmentet ligger udenfor byzone (0), i byzone (1) eller i miljøzone (2). Da miljøzoner funktionelt svarer til byzone, behandles variabelen som binær.

Variabeloversigt

Tabel 4: Oversigt over variable og deres koefficientindeks i **X**-, **Z**- og **W**-modellerne. Tomme felter angiver, at variablen ikke indgår i den pågældende delmodel.

Variabel	X	Z	W
Intercept	x0	z0	w0
Frac_Truck	x1	z1	
SpeedDiff_Car_Van	x2		
SpeedDiff_Truck	x3		
FreeSpeed		z2	
URBAN	x4	z3	
Link_group_0	x5	z4	w1
Link_group_1	x6	z5	w2
Link_group_2	x7	z6	w3
Link_group_3	x8	z7	w4
Region Hovedstaden	x9	z8	
Region Sjælland	x10	z9	
Region Syddanmark	x11	z10	
Region Midtjylland	x12	z11	
Region Nordjylland	x13	z12	

4 Validering af Model

Modellen valideres ved k -fold cross-validation, hvor der i hver fold udregnes Randomized Quantile Residuals på testdata. Det undersøges, om disse Randomized Quantile Residuals har den forventede standard normalfordeling ved brug af statistiske test.

4.1 k -fold cross-validation

k -fold cross-validation er en metode til at vurdere en models generaliserings-evne på nye data. Dataene opdeles i k omtrent lige store delmængder. Disse delmængder kaldes "fold". Modellen trænes på $k - 1$ fold og testes på den resterende fold. Processen gentages k gange, så hver fold bruges én gang som testdata. Til sidst beregnes den gennemsnitlige præstation over alle fold, hvilket giver en mere pålidelig vurdering af modellens ydeevne sammenlignet med en enkelt trænings-/test-split. Valget af k er en afvejning mellem bias, varians og beregningstid. Et lille k giver typisk højere bias, men lavere varians og kortere beregningstid, mens et større k reducerer bias, men kan øge variansen og kræve mere beregning[8]. I praksis anvendes ofte $k = 5$ og $k = 10$ [10].

4.2 Randomized Quantile Residuals (RQR)

Randomized Quantile Residuals (RQR) benyttes, da modeller for diskrete tælleverdier ikke nødvendigvis har normalfordelte residualer — særligt i situationer hvor fordelingerne har små forventede værdier, da effekten af diskretthed på klassiske residualmål bliver specielt dominerende i sådanne situationer[11]. RQR kompenserer for diskontinuiteten i den kumulative fordelingsfunktion, som opstår ved diskrete tællevariable, ved at anvende en stokastisk transformation af den kumulative fordelingsfunktion. Under en korrekt specificeret model vil disse residualer være uafhængige og standard-normalt fordelte[11].

Residualerne udregnes ved først at trække en tilfældig værdi

$$u_i \sim \mathcal{U}(F(y_i - 1|\mu_i), F(y_i|\mu_i)), \quad (23)$$


hvor $\mathcal{U}(a, b)$ er en kontinuér uniform fordeling på intervallet $[a, b]$, og $F(y|\mu) = \mathbb{P}(Y \leq y|\mu)$ er den kumulative fordelingsfunktion.

Denne værdi transformeres derefter med den inverse standard normalfordeling:

$$r_i = \Phi^{-1}(u_i), \quad (24)$$

hvor Φ^{-1} er den inverse CDF for $\mathcal{N}(0, 1)$ (Se Figur 2).

For at tjekke om modellen i tilstrækkelig grad er korrekt parametriseret foretages en række statiske teste. Dette gøres for at undersøge, om udregnede RQR har en standard normal fordeling.



Figur 2: Illustration af beregning af Randomized Quantile Residuals (RQR). (venstre) Den observerede værdi indsættes i model-CDF'en, hvorefter en stokastiskuniform værdi trækkes i intervallet $[F(y - 1), F(y)]$. (højre) Denne værdi transformeres derefter med den inverse standard normalfordeling. Resultatet er $RQR = -0.659$ for den givne model ved observation $Y = 2$

4.3 T-test

Der foretages en et-sidet t-test for at bestemme, om middelværdien af RQR er signifikant forskellig fra 0. Dette gøres ved at beregne teststørrelsen:

$$t = \frac{\overline{\text{RQR}}}{s/\sqrt{n}} \quad (25)$$

hvor $\overline{\text{RQR}}$ er middelværdien af de randomiserede kvantilresidualer, s er standardafvigelsen, og n er antallet af observationer. Under nulhypotesen antages det, at residualerne har middelværdi nul.

Herefter beregnes p-værdien som sandsynligheden for at observere en t -værdi mindst lige så ekstrem som den observerede, givet en t -fordeling med $n - 1$ frihedsgrader. Dette gøres ved:

$$p = 2 \cdot \mathbb{P}(T > |t|) \quad (26)$$

Den beregnede p-værdi anvendes til at vurdere, om nulhypotesen kan forkastes ved et givent signifikansniveau[13].

4.4 χ^2 -test

For normalfordelte og uafhængige observationer, følger den skalerede stikprøvevarians en χ^2 -fordeling:

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2 \quad (27)$$

hvor $s^2 = \frac{\sum (y_i - \bar{y})^2}{n-1}$ er unbiased stikprøvevarians, σ^2 er den sande (ukendte) varians, og n er antal observationer.

Dette giver grundlaget for at opstille et konfidensinterval for σ^2 . Betragt udtrykket for sandsynligheden

$$\mathbb{P}\left(\chi_{\alpha/2}^2 \leq \frac{(n-1)s^2}{\sigma^2} \leq \chi_{1-\alpha/2}^2\right) = 1 - \alpha \quad (28)$$

hvor χ_a^2 er den a -kvantil af χ^2 -fordelingen med $n - 1$ frihedsgrader. herfra fås følgende σ^2 -konfidensinterval :

$$\left[\frac{(n-1)s^2}{\chi_{1-\alpha/2}^2}, \frac{(n-1)s^2}{\chi_{\alpha/2}^2} \right] \quad (29)$$

Dette interval udgør et $(1 - \alpha)$ -konfidensinterval for variansen. Hvis 1 er indeholdt i intervallet, så er variansen af residualerne ikke signifikant afvigende fra standard normalfordelingens varians. For denne test udregnes p-værdien ved:

$$p = 2 \cdot \min \{ \mathbb{P}(\chi_{n-1}^2 \leq \chi_{\text{obs}}^2), \mathbb{P}(\chi_{n-1}^2 \geq \chi_{\text{obs}}^2) \} \quad (30)$$

[13].

4.5 Kolmogorov–Smirnov-test

Kolmogorov–Smirnov-testen (KS-testen) anvendes til at vurdere, om en stikprøve følger en specifik referencefordeling — her standard normalfordelingen $\mathcal{N}(0, 1)$. Testen er ikke-parametrisk og baserer sig på den største afvigelse mellem den empiriske fordelingsfunktion (EDF) og den kumulative fordelingsfunktion (CDF) for referencefordelingen [9].

Teststørrelsen defineres som:

$$D_n = \sup_x |F_n(x) - F(x)| \quad (31)$$

hvor:

- $F_n(x)$ er den empiriske fordelingsfunktion for stikprøven.
- $F(x)$ er den teoretiske kumulative fordelingsfunktion for den antaget fordeling.

Under nulhypotesen: data følger den angivne referencefordeling, kan D_n sammenholdes til Kolmogorov-fordelingen for at beregne en p-værdi ved:

$$p = \mathbb{P}(K > \sqrt{n}D_n) \quad (32)$$

hvor K følger Kolmogorov-fordelingen. Dette udregnes med Kolmogorovs asymptotiske formel:

$$\mathbb{P}(K \geq \lambda) = 2 \sum_{k=1}^{\infty} (-1)^{k-1} \exp(-2k^2 \lambda^2) \quad (33)$$

for $\lambda = \sqrt{n}D_n$ [12]

KS-testen bruges til at vurdere, om de randomiserede kvantilresidualer (RQR) kan antages at følge en standardnormalfordeling.

5 Resultater

For at validere modellens evne til at generalisere til hidtil uset data anvendes k-fold cross-validation med $k = 5$.

Parametre og prædiktive resultater er præsenteret i nedenstående tabeller. Derudover er randomized quantile residuals (RQR) beregnet og visualiseret (se Figur 3).

De tilhørende statistiske test er udført på RQR'erne, og de resulterende p-værdier fremgår af figuren.

Fold	Komponent	Observeret	Forudsagt	Forhold
1	Samlet antal uheld	801	819.63	1.023
1	Personskadeuheld	156	150.02	0.962
1	Let tilskadekomne	56	60.30	1.077
1	Alvorligt tilskadekomne	113	106.54	0.943
1	Trafikdræbte	14	10.68	0.763
2	Samlet antal uheld	841	870.17	1.035
2	Personskadeuheld	140	165.51	1.182
2	Let tilskadekomne	60	63.63	1.060
2	Alvorligt tilskadekomne	86	121.55	1.413
2	Trafikdræbte	16	10.99	0.687
3	Samlet antal uheld	822	853.42	1.038
3	Personskadeuheld	140	162.59	1.161
3	Let tilskadekomne	47	66.17	1.408
3	Alvorligt tilskadekomne	97	116.22	1.198
3	Trafikdræbte	11	11.97	1.088
4	Samlet antal uheld	835	807.73	0.967
4	Personskadeuheld	173	149.61	0.865
4	Let tilskadekomne	68	58.47	0.860
4	Alvorligt tilskadekomne	133	103.70	0.780
4	Trafikdræbte	10	12.01	1.201
5	Samlet antal uheld	803	823.70	1.026
5	Personskadeuheld	153	155.92	1.019
5	Let tilskadekomne	68	58.99	0.868
5	Alvorligt tilskadekomne	113	109.89	0.973
5	Trafikdræbte	6	13.11	2.185

Tabel 5: Observerede og forudsagte værdier for de forskellige modelkomponenter på tværs af fem fold. Forholdet angiver forholdet mellem forudsagte og observerede værdier.

Tabel 5 opsummerer modellens præstation på tværs af foldene. Overordnet estimerer modellen det samlede ulykkesniveau stabilt, mens de efterfølgende trin i hierarkiet udviser stigende usikkerhed. Udsvingene bliver særligt tydelige for de mest sjældne hændelsestyper, hvilket indikerer, at fold-til-fold variation i datagrundlaget får større betydning, når antallet af observationer er lavt. For dødsulykker afviger ratioen markant fra én. Dette kan dels skyldes, at små stikprøver giver større varians i de estimerede forhold, dels at datagrundlaget er for sparsomt til at skabe et robust signal.

Tabel 6, 7, 8, 9 og 10 viser de estimerede regressionkoefficienter på tværs af de fem fold for hver modelkomponent i den hierarkiske uheldsmodel. Tabel 4 angiver, hvilke forklarende variable der indgår i henholdsvis frekvensmodellen (**X**), personskademodellen (**Z**) og fordelingen af skadesgrad (**W**). Variabelnavnene i koefficienttabellerne refererer direkte til kolonnerne i 4 efter samme rækkefølge. Et konsistent fortegn og en sammenlignelig størrelsesorden på tværs af fold in-

dikerer, at variablerne har en stabil og robust indvirkning på modellens respons. Dette tyder på, at effekterne ikke er følsomme over for datasplit. Flere variable har koefficienter med både positivt og negativt fortegn og er samtidig tæt på nul på tværs af fold, hvilket indikerer, at deres marginale effekt på udfaldet er begrænset i den estimerede model. Dette kan skyldes, at deres effekt allerede er opfanget af andre, korrelerede variable i modellen. Et eksempel herpå ses for $w1$ i modellen for lette personskader, som repræsenterer `Link_group_0`. Denne variabel afviger markant fra nul og ligger konsistent i intervallet 0.31–0.38 på tværs af fold. I kontrast hertil har $w2$ og $w3$ koefficienter med skiftende fortegn og værdier tæt på nul. Dette indikerer, at det forventede antal let tilskadekomne, givet at et uheld er indtruffet, er højere på motorveje end på de øvrige vejtyper repræsenteret ved $w2$ og $w3$

Fold	x0	x1	x2	x3	x4	x5	x6	x7	x8	x9	x10	x11	x12	x13
1	-17.74	0.49	0.01	-0.02	0.76	-0.29	-0.11	0.25	-0.06	0.07	-0.28	0.09	-0.03	-0.30
2	-18.01	1.06	0.01	-0.02	0.75	-0.24	0.01	0.32	-0.01	0.25	-0.12	0.20	0.05	-0.06
3	-18.00	1.38	0.01	-0.03	0.79	-0.20	-0.00	0.38	-0.01	0.17	-0.18	0.15	-0.01	-0.17
4	-17.94	1.14	0.02	-0.03	0.75	-0.21	0.01	0.38	-0.02	0.13	-0.20	0.11	-0.00	-0.18
5	-18.00	0.87	0.01	-0.01	0.74	-0.21	0.01	0.32	-0.02	0.24	-0.08	0.23	0.09	-0.07

Tabel 6: Estimated coefficients for frequency (beta model) across folds.

Fold	z0	z1	z2	z3	z4	z5	z6	z7	z8	z9	z10	z11	z12
1	-2.48	-0.06	0.01	-0.01	-0.94	0.38	0.60	-0.25	0.02	0.01	-0.21	-0.03	0.10
2	-2.33	-0.10	0.01	-0.03	-1.00	0.45	0.62	-0.17	0.03	0.02	-0.25	-0.06	0.29
3	-2.46	-0.01	0.01	-0.00	-1.15	0.36	0.57	-0.11	-0.01	0.15	-0.27	-0.03	0.22
4	-2.57	0.07	0.01	-0.00	-1.14	0.35	0.55	-0.09	0.02	0.02	-0.20	-0.04	0.34
5	-2.37	-0.03	0.01	0.00	-0.93	0.45	0.59	-0.14	0.02	0.09	-0.25	-0.09	0.27

Tabel 7: Estimated coefficients for injury count (gamma model) across folds.

Fold	w0	w1	w2	w3	w4
1	-0.96	0.35	0.01	-0.01	-0.19
2	-0.99	0.33	-0.04	0.02	-0.36
3	-0.94	0.38	0.00	-0.01	-1.18
4	-0.97	0.32	-0.01	0.00	-0.30
5	-1.00	0.31	-0.01	-0.01	-0.40

Tabel 8: Estimated coefficients for slight injuries (delta_slight model) across folds.

Fold	w0	w1	w2	w3	w4
1	-0.34	0.02	0.01	-0.02	-0.09
2	-0.31	0.00	0.02	-0.03	0.02
3	-0.34	-0.01	0.04	-0.02	0.03
4	-0.36	0.02	0.01	-0.02	-0.03
5	-0.37	-0.03	0.06	-0.01	-0.05


Tabel 9: Estimated coefficients for serious injuries (delta_serious model) across folds.

Fold	w0	w1	w2	w3	w4
1	-2.57	-0.07	0.08	-0.24	0.51
2	-2.83	0.15	0.30	-0.12	-0.38
3	-2.44	-0.02	0.07	-0.48	0.35
4	-2.68	-0.47	0.47	-0.10	0.44
5	-2.48	-0.12	0.12	-0.10	0.37

Tabel 10: Estimated coefficients for fatal injuries (delta_fatal model) across folds.

Til evaluering af modellens evne til at forudsige antallet af uheld anvendes Randomized Quantile Residuals (RQR). Normaliteten af RQR vurderes ved hjælp af en t-test, en χ^2 -test og en Kolmogorov-Smirnov-test. Endvidere sammenholdes RQR visuelt med en standardnormalfordeling i et QQ-plot. Resultaterne fremgår af Figur 3.

QQ-plots af Randomized Quantile Residuals viser generelt god overensstemmelse med en standardnormalfordeling på tværs af fold og modelkomponenter. De statistiske tests understøtter denne vurdering, idet langt størstedelen af testene ikke afviser normalitet. For delmodellerne for let og svært tilskadekomne ses en tendens til overdispersion, idet den højre hale ligger over reference-linjen for hver fold. Disse afvigelser opfanges ikke entydigt af de statistiske tests, hvorfor der ikke findes belæg for væsentlig modelmisfit.



Figur 3: QQ-plots for Randomized Quantile Residuals (RQR) på tværs af alle fold og uheldstyper. Den røde linje angiver teoretisk normalitet. Til højre i hvert subplot vises p-værdier fra t-test (middelværdi = 0), χ^2 -test (varians = 1) og KS-test for normalfordeling. P-værdier under 0.05 er markeret med fed rød tekst.

6 Diskussion

Den fremlagte metode forudsiger antal uheld på baggrund af GMM-output. Modellen synes i tilstrækkelig grad at kunne generalisere til ikke tidligere sete vejstrækninger, idet RQR fra 5-fold cross-validation udviser en tilnærmelsesvis normalfordeling, jf. Figur 3.

Det er dog ikke i tilstrækkelig grad undersøgt, om en simplere model kan opnå tilsvarende performance. Eksempelvis kan information om parameterusikkerhed anvendes til at vurdere, om parametre er statistisk signifikante, eller om nogle med fordel kan udelades for at opnå en mere parsimonisk model. Derudover bør modellens resultater sammenholdes med en simpel baseline-model, som angiver et minimumsniveau for performance. Dette er nødvendigt for at vurdere, om den øgede modelkompleksitet er berettiget.

En yderligere undersøgelse bør fokusere på, om inddragelse af flere parametre kan forbedre modellens præcision. De modelinput, der vedrører hastighed, var oprindeligt tænkt som en proxy for trængsel. Modellen er dog baseret på gennemsnit over et helt døgn, hvilket kan medføre, at denne proxy udglattes af hastigheder i perioder uden for myldretiden. En mere repræsentativ proxy kunne derfor være at anvende den laveste observerede hastighed på tværs af de 10 tidsbånd, der udgør et døgn i GMM.

Yderligere kan det undersøges, om en ZINB-model (Zero-Inflated Negative Binomial) bedre kan repræsentere de observerede uheld. Flere af delmodellerne udviste tendenser til, at den øvre hale ligger over referencelinjen i QQ-plottene. Dette kan indikere, at modellen ikke i tilstrækkelig grad fanger fordelingen af ekstreme observationer. Det kan derfor være relevant at overveje en modelstruktur, der i højere grad kan håndtere overrepræsentation af nulobservationer og samtidig bedre beskrive haleadfærden i data.

Litteratur

- [1] Wei Bai, Mei Dong, Longhai Li, Cindy Feng, and Wei Xu. Randomized quantile residuals for diagnosing zero-inflated generalized linear mixed models with applications to microbiome count data. *BMC Bioinformatics*, 22(1):564, 2021. doi:10.1186/s12859-021-04371-6.
- [2] James O. Berger. *Statistical Decision Theory and Bayesian Analysis*. Springer, New York, 2nd edition, 1985. See Section 3.5.5: Moment Estimation of Hyperparameters.
- [3] Richard H. Byrd, Peihuang Lu, Jorge Nocedal, and Ciyu Zhu. A limited memory algorithm for bound constrained optimization. *SIAM Journal on Scientific Computing*, 16(5):1190–1208, 1995. arXiv:<https://doi.org/10.1137/0916069>, doi:10.1137/0916069.
- [4] Danmarks Meteorologiske Institut. Danmarks klima 2023: DMI Rapport 24-01. Technical report, Danmarks Meteorologiske Institut, 2024. Accessed: 2025-07-09. URL: <https://www.dmi.dk/fileadmin/Rapporter/2024/DMIRap24-01.pdf>.
- [5] Nader Fallah, Hong Gu, Kazem Mohammad, Seyyed Seyyedsalehi, Keramat Nourijelyani, and Mohammad Eshraghian. Nonlinear poisson regression using neural networks: A simulation study. *Neural Computing and Applications*, 18:939–943, 11 2009. doi:10.1007/s00521-009-0277-8.
- [6] GeoPandas contributors. GeoPandas: Python tools for geographic data, 2024. URL: <https://geopandas.org>.
- [7] Joseph M. Hilbe. *Negative Binomial Regression*. Cambridge University Press, 2 edition, 2011.
- [8] Ron Kohavi. A study of cross-validation and bootstrap for accuracy estimation and model selection. 14, 03 2001.
- [9] Frank J. Massey. The kolmogorov-smirnov test for goodness of fit. *Journal of the American Statistical Association*, 46(253):68–78, 1951. URL: <http://www.jstor.org/stable/2280095>.
- [10] Jalaj Pachouly, Swati Ahirrao, Ketan Kotecha, Ganeshsree Selvachandran, and Ajith Abraham. A systematic literature review on software defect prediction using artificial intelligence: Datasets, data validation methods, approaches, and tools. *Engineering Applications of Artificial Intelligence*, 111:104773, 2022. URL: <https://www.sciencedirect.com/science/article/pii/S0952197622000616>, doi:10.1016/j.engappai.2022.104773.
- [11] Kayoung Park, Dongmin Jung, and Jong-Min Kim. Control charts based on randomized quantile residuals. *Applied Stochastic Models in Business and Industry*, 36(4):716–729, 2020. URL: <https://doi.org/10.1016/j.asm.2020.07.001>.

[//onlinelibrary.wiley.com/doi/abs/10.1002/asmb.2527](https://onlinelibrary.wiley.com/doi/abs/10.1002/asmb.2527), arXiv:
<https://onlinelibrary.wiley.com/doi/pdf/10.1002/asmb.2527>,
doi:10.1002/asmb.2527.

- [12] Jan Vrbik. Deriving cdf of kolmogorov-smirnov test statistic. *Applied Mathematics*, 11:227–246, 01 2020. doi:10.4236/am.2020.113018.
- [13] Dennis D. Wackerly, William Mendenhall, and Richard L. Scheaffer. *Mathematical Statistics with Applications*. Cengage Learning, 7 edition, 2008.
- [14] Rainer Winkelmann. *Poisson Regression*, pages 63–126. Springer Berlin Heidelberg, Berlin, Heidelberg, 2008. doi:10.1007/978-3-540-78389-3_3.

7 Bilag

7.1 Github-Repository

Koden som er brugt til at estimere parameter for modellen er findes i Github-Repository. Følg nedenstående link

Link til Github-Repository

7.2 Forventet ulykkestal ved vejopdeling

Når et nyt scenarie opsættes i GMM, tilføjes nye vejsegmenter, hvilket medfører, at de oprindelige vejsegmenter opdeles i flere dele. Det er derfor vigtigt at sikre, at denne opdeling ikke påvirker det forventede antal uheld i basisscenariet.

Det forventede antal uheld er givet ved

$$\mathbb{E}(N) = \lambda \exp(X^\top \beta) = \lambda \omega,$$

hvor λ og ω er funktioner. Ved en opsplitning af et vejsegment skal derfor gælde

$$\begin{aligned}\mathbb{E}(N) &= \mathbb{E}(N_1) + \mathbb{E}(N_2), \\ \lambda \omega &= \lambda_1 \omega_1 + \lambda_2 \omega_2.\end{aligned}$$

Da kun segmenternes længde ændres, mens den samlede længde bevares, kan der indføres en andel $\alpha \in (0, 1)$, således at

$$L_1 = \alpha L, \quad L_2 = (1 - \alpha)L.$$

Da

$$\lambda = \text{længde} \times \text{antal køretøjer},$$

og antallet af køretøjer pr. længdeenhed antages uændret ved opsplitningen, følger det, at

$$\lambda_1 = \alpha \lambda, \quad \lambda_2 = (1 - \alpha) \lambda.$$

Desuden antages ω at være uændret for de opdelte vejsegmenter, således at

$$\omega_1 = \omega_2 = \omega.$$

Dermed fås

$$\lambda_1 \omega_1 + \lambda_2 \omega_2 = \alpha \lambda \omega + (1 - \alpha) \lambda \omega = \lambda \omega.$$

Det totale forventede antal uheld er således uændret ved opsplitning af vejsegmentet.

Den binomiale model, som anvendes til at modellere andelen af uheld med personskaade, har forventningsværdi

$$\mathbb{E}(Y) = \text{logit}^{-1}(Z_i^\top \gamma) \mathbb{E}(N).$$

Det antages, at

$$p = \text{logit}^{-1}(Z_i^\top \gamma)$$

er uændret for de opdelte vejsegmenter. Dermed fås

$$\begin{aligned}\mathbb{E}(Y) &= p \mathbb{E}(N), \\ \mathbb{E}(Y_1) &= p \mathbb{E}(N_1), \\ \mathbb{E}(Y_2) &= p \mathbb{E}(N_2).\end{aligned}$$

Da $\mathbb{E}(N) = \mathbb{E}(N_1) + \mathbb{E}(N_2)$, følger det direkte, at

$$\mathbb{E}(Y) = \mathbb{E}(Y_1) + \mathbb{E}(Y_2),$$

idet begge sider multipliceres med den konstante faktor p .

For hver skadestype $q^{(i)}$ kan et tilsvarende argument anvendes, idet modellen er opbygget på samme form. Ved opsplitning summerer eksponeringsmålet over de nye segmenter til samme samlede eksponering som for det oprindelige, ikke-opdelte vejsegment. Dermed bevares den forventede værdi også for hver skadestype under de tilsvarende antagelser om uændrede risikofaktorer. Af hensyn til læsbarhed udelades det fulde bevis.

Samlet set er det forventede antal uheld og skader således uændret ved opsplitning af et vejsegment, forudsat at inputparametrene holdes konstante.

Bemærkning. Hvis et vejsegment opsplittes antages at kun vejens nye segmenters attributer har samme størrelse som det originale vejsegment med undtagelse af vejlængden. Er det ikke tilfældet, så gælder bevarelsen af det forventede ulykkestal nødvendigvis ikke?

7.3 Udledninger af Log-likelihood og Hessematricer for hver model

7.3.1 Totalt antal uheld

For at modellere det totale antal uheld benyttes en Negativ binomial fordeling. Den specifikke parametrisering er NB2-varianten, hvor variansen afhænger kvadratisk af middelværdien. Fordelingen er

$$Y_i \sim \text{NB2}(\mu_i, \alpha), \quad r = \frac{1}{\alpha}, \quad (34)$$

med sandsynlighedsmassen

$$\mathbb{P}(Y_i = y_i \mid \mu_i, \alpha) = \binom{y_i + r - 1}{y_i} \left(\frac{r}{r + \mu_i} \right)^r \left(\frac{\mu_i}{r + \mu_i} \right)^{y_i}. \quad (35)$$

Middelværdien modelleres via en log-linkfunktion

$$\eta_i = \log \mu_i = \log \lambda_i + \mathbf{x}_i^\top \boldsymbol{\beta}, \quad \mu_i = \lambda_i \exp(\mathbf{x}_i^\top \boldsymbol{\beta}). \quad (36)$$

Log-likelihood

Den logaritmiske likelihood er

$$\ell(\boldsymbol{\beta}, \alpha) = \sum_{i=1}^n \left[\log \Gamma(y_i + r) - \log \Gamma(r) - \log \Gamma(y_i + 1) + r \log \left(\frac{r}{r + \mu_i} \right) + y_i \log \left(\frac{\mu_i}{r + \mu_i} \right) \right]. \quad (37)$$

hvor

$$r = \frac{1}{\alpha}, \quad p_i = \frac{r}{r + \mu_i}. \quad (38)$$

bemærk $\eta_i = \log \mu_i = \log \lambda_i + \mathbf{x}_i^\top \boldsymbol{\beta}$ og $\mu_i = e^{\eta_i}$ anvendes i afledningerne nedenfor.

Gradient

Den afledte log-likelihood med hensyn til η_i er

$$\frac{\partial \ell}{\partial \eta_i} = \frac{y_i - \mu_i}{1 + \alpha \mu_i}. \quad (39)$$

Ved kædereformen fås gradienten med hensyn til $\boldsymbol{\beta}$:

$$\frac{\partial \ell}{\partial \boldsymbol{\beta}} = \sum_i \frac{y_i - \mu_i}{1 + \alpha \mu_i} \mathbf{x}_i = \mathbf{X}^\top \mathbf{s}, \quad (40)$$

hvor

$$s_i = \frac{y_i - \mu_i}{1 + \alpha \mu_i}. \quad (41)$$

Hessematricen

Andenaafledte af log-likelihooden med hensyn til η_i er

$$\frac{\partial^2 \ell}{\partial \eta_i^2} = - \frac{(1 + \alpha y_i) \mu_i}{(1 + \alpha \mu_i)^2}. \quad (42)$$

Hessematricen for $\boldsymbol{\beta}$ fremkommer som

$$\frac{\partial^2 \ell}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^\top} = \sum_i \frac{\partial^2 \ell}{\partial \eta_i^2} \mathbf{x}_i \mathbf{x}_i^\top = \mathbf{X}^\top \mathbf{D} \mathbf{X}, \quad (43)$$

hvor

$$\mathbf{D} = \text{diag}(\mathbf{d}), \quad d_i = - \frac{(1 + \alpha y_i) \mu_i}{(1 + \alpha \mu_i)^2}. \quad (44)$$

I optimeringen anvendes den negative Hessian

$$\mathbf{H}_{\text{NB}}(\boldsymbol{\beta}) = - \mathbf{X}^\top \mathbf{D} \mathbf{X}. \quad (45)$$

7.3.2 Antal personskadeuheld

Antallet af personskadeuheld modelleres betinget på det totale antal uheld Y_i ved en binomialfordeling,

$$Y_i^{(p)} \mid Y_i, p_i \sim \text{Binomial}(Y_i, p_i), \quad (46)$$

med massefunktion

$$\mathbb{P}(Y_i^{(p)} = y_i^{(p)} \mid Y_i, p_i) = \binom{Y_i}{y_i^{(p)}} p_i^{y_i^{(p)}} (1 - p_i)^{Y_i - y_i^{(p)}}. \quad (47)$$

For at sikre $p_i \in (0, 1)$ benyttes logit-link:

$$\eta_i^{(p)} = \mathbf{z}_i^\top \boldsymbol{\gamma}, \quad p_i = \frac{1}{1 + e^{-\eta_i^{(p)}}}. \quad (48)$$

Log-likelihood

Den logaritmiske likelihood er

$$\begin{aligned} \ell(\boldsymbol{\gamma}) = \sum_{i=1}^n & \left[\log \Gamma(Y_i + 1) - \log \Gamma(y_i^{(p)} + 1) - \log \Gamma(Y_i - y_i^{(p)} + 1) \right. \\ & \left. + y_i^{(p)} \log p_i + (Y_i - y_i^{(p)}) \log(1 - p_i) \right]. \end{aligned} \quad (49)$$

Gradient

Da

$$\frac{\partial p_i}{\partial \eta_i^{(p)}} = p_i(1 - p_i), \quad (50)$$

fås

$$\frac{\partial \ell}{\partial \boldsymbol{\gamma}} = \sum_i (y_i^{(p)} - Y_i p_i) \mathbf{z}_i. \quad (51)$$

I matrixform:

$$\nabla_{\boldsymbol{\gamma}} \ell = \mathbf{Z}^\top (\mathbf{y}^{(p)} - \mathbf{y} \odot \mathbf{p}), \quad (52)$$

hvor $\odot$ betegner elementvis multiplikation, $\mathbf{y}^{(p)} = (y_1^{(p)}, \dots, y_m^{(p)})^\top$ og $\mathbf{y} = (y_1, \dots, y_m)^\top$.

Hessematricen

Andenaflædte i $\eta_i^{(p)}$ er

$$\frac{\partial^2 \ell}{\partial (\eta_i^{(p)})^2} = -Y_i p_i(1 - p_i). \quad (53)$$

Hessematricen er derfor

$$\frac{\partial^2 \ell}{\partial \boldsymbol{\gamma} \partial \boldsymbol{\gamma}^\top} = \sum_i \frac{\partial^2 \ell}{\partial (\eta_i^{(p)})^2} \mathbf{z}_i \mathbf{z}_i^\top = -\mathbf{Z}^\top \mathbf{W} \mathbf{Z}, \quad (54)$$

hvor

$$\mathbf{W} = \text{diag}(Y_i p_i (1 - p_i)). \quad (55)$$

Den negative Hessian, som anvendes i optimeringen, er

$$\mathbf{H}_{\text{Bin}}(\gamma) = \mathbf{Z}^\top \mathbf{W} \mathbf{Z}. \quad (56)$$

7.3.3 Antal tilskadekomne

Antallet af tilskadekomne opdeles i tre grupper:

$$q_i^{(1)} \text{ (let tilskadekomne), } \quad q_i^{(2)} \text{ (svært tilskadekomne), } \quad q_i^{(3)} \text{ (dødsfald).}$$

Hver af disse modelleres med en NB2-fordeling

$$q_i^{(j)} \sim \text{NB2}(\mu_i^{(j)}, \alpha_j), \quad j \in \{1, 2, 3\}, \quad (57)$$

hvor sandsynlighedsmassen er

$$\mathbb{P}(q_i^{(j)} = n \mid \mu_i^{(j)}, \alpha_j) = \binom{n + r_j - 1}{n} \left(\frac{r_j}{r_j + \mu_i^{(j)}} \right)^{r_j} \left(\frac{\mu_i^{(j)}}{r_j + \mu_i^{(j)}} \right)^n, \quad (58)$$

og $r_j = \frac{1}{\alpha_j}$. Her anvendes et log-link, hvor middelværdien er

$$\eta_i^{(j)} = \log \mu_i^{(j)} = \log Y_i + \mathbf{w}_i^\top \boldsymbol{\delta}^{(j)} \quad \implies \quad \mu_i^{(j)} = Y_i \exp(\mathbf{w}_i^\top \boldsymbol{\delta}^{(j)}), \quad (59)$$

så antallet af tilskadekomne er proportionalt med det observerede antal personskadeuheld Y_i .

Log-likelihood

Log-likelihooden for parametersættet $\boldsymbol{\delta}^{(j)}$ (givet α_j) er

$$\ell(\boldsymbol{\delta}^{(j)}, \alpha^{(j)}) = \sum_i \log \mathbb{P}(q_i^{(j)} \mid \boldsymbol{\delta}^{(j)}, \alpha_j). \quad (60)$$

hvilket for denne fordeling giver

$$\begin{aligned} \ell(\boldsymbol{\delta}^{(j)}, \alpha^{(j)}) = \sum_{i=1}^n & \left[\log \Gamma(y_i + r) - \log \Gamma(r) - \log \Gamma(y_i + 1) \right. \\ & \left. + r \log \left(\frac{r}{r + \mu_i} \right) + y_i \log \left(\frac{\mu_i}{r + \mu_i} \right) \right], \end{aligned} \quad (61)$$

hvor

$$r = \frac{1}{\alpha}, \quad p_i = \frac{r}{r + \mu_i}. \quad (62)$$

Med og hvor lineær prædiktør er givet ved

$$\eta_i^{(j)} = \log Y_i + \mathbf{w}_i^\top \boldsymbol{\delta}^{(j)}, \quad \mu_i^{(j)} = e^{\eta_i^{(j)}}, \quad (63)$$

kan alle afledninger gennemføres analogt til NB-modellen for totaluheld.

Gradient

Gradienten af log-likelihooden med hensyn til $\eta_i^{(j)}$ er

$$\frac{\partial \ell}{\partial \eta_i^{(j)}} = \frac{\delta_i^{(j)} - \mu_i^{(j)}}{1 + \alpha_j \mu_i^{(j)}}. \quad (64)$$

Ved kædereglen fås gradienten med hensyn til $\boldsymbol{\delta}^{(j)}$:

$$\frac{\partial \ell}{\partial \boldsymbol{\delta}^{(j)}} = \sum_i \frac{\delta_i^{(j)} - \mu_i^{(j)}}{1 + \alpha_j \mu_i^{(j)}} \mathbf{w}_i = \mathbf{W}^\top \mathbf{s}^{(j)}, \quad (65)$$

hvor

$$\mathbf{s}_i^{(j)} = \frac{\delta_i^{(j)} - \mu_i^{(j)}}{1 + \alpha_j \mu_i^{(j)}}. \quad (66)$$

Hessematricen

Andenaflædte i $\eta_i^{(j)}$ er

$$\frac{\partial^2 \ell}{\partial (\eta_i^{(j)})^2} = - \frac{(1 + \alpha_j \delta_i^{(j)}) \mu_i^{(j)}}{(1 + \alpha_j \mu_i^{(j)})^2}. \quad (67)$$

Hermed fås Hessianen:

$$\frac{\partial^2 \ell}{\partial \boldsymbol{\delta}^{(j)} \partial (\boldsymbol{\delta}^{(j)})^\top} = \sum_i \frac{\partial^2 \ell}{\partial (\eta_i^{(j)})^2} \mathbf{w}_i \mathbf{w}_i^\top = \mathbf{W}^\top \mathbf{D}^{(j)} \mathbf{W}, \quad (68)$$

hvor $\mathbf{D}^{(j)}$ er diagonal med elementer

$$D_{ii}^{(j)} = - \frac{(1 + \alpha_j \delta_i^{(j)}) \mu_i^{(j)}}{(1 + \alpha_j \mu_i^{(j)})^2}. \quad (69)$$

I optimeringen bruges den negative Hessian:

$$\mathbf{H}_{\text{NB}}^{(j)} = - \mathbf{W}^\top \mathbf{D}^{(j)} \mathbf{W}. \quad (70)$$